МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ ФЕДЕРАЦИИ
Федеральное государственное автономное образовательное учреждение
высшего образования
**«Южно-Уральский государственный университет
(национальный исследовательский университет)»**
Высшая школа электроники и компьютерных наук
Кафедра системного программирования

ДОПУСТИТЬ К ЗАЩИТЕ

Заведующий кафедрой, д.ф.-м.н.,
профессор

_____ Л.Б. Соколинский

«___»_____ 2022 г.

Препроцессинг данных для системы управления отоплением зданий

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА
ЮУрГУ – 09.03.04.2022.308-247.ВКР

Научный руководитель,
профессор кафедры СП, д.ф.-м.н.,
доцент
_____ М.Л. Цымблер

Автор работы,
студент группы КЭ-404
_____ Е.А. Латыпова

Ученый секретарь
(нормоконтролер)
_____ И.Д. Володченко
«___»_____ 2022 г.

Челябинск, 2022 г.

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ ФЕДЕРАЦИИ
Федеральное государственное автономное образовательное учреждение
высшего образования
**«Южно-Уральский государственный университет
(национальный исследовательский университет)»**
Высшая школа электроники и компьютерных наук
Кафедра системного программирования

УТВЕРЖДАЮ
Зав. кафедрой СП
_____ Л.Б. Соколинский
07.02.2022 г.

ЗАДАНИЕ
на выполнение выпускной квалификационной работы бакалавра
студенту группы КЭ-404
Латыповой Елизавете Альбертовне,
обучающейся по направлению
09.03.04 «Программная инженерия»

1. **Тема работы** (утверждена приказом ректора от 25.04.2022 г. № 697-13/12)
Препроцессинг данных для системы управления отоплением зданий.
2. **Срок сдачи студентом законченной работы:** 06.06.2022.
3. **Исходные данные к работе**

3.1. Басалаев А.А. Автоматизированный энергоменеджмент теплоэнергетического комплекса университетского городка // Вестник ЮУрГУ. Серия «Компьютерные технологии, управление, радиоэлектроника». 2015. Т. 15, № 4. С. 26–32. DOI: 10.14529/ctcr150403.
3.2. Нетбай Г.В., Онискив В.Д., Столбов В.Ю., Каримов Р.Р. Прогнозное управление локальной городской системой теплоснабжения на основе нейросетевого моделирования // Вестник ЮУрГУ. Серия «Компьютерные технологии, управление, радиоэлектроника». 2019. № 3(47). С. 28–38. DOI: 10.14529/ctcr200303.
3.3. Нетбай Г.В., Онискив В.Д., Столбов В.Ю., Каримов Р.Р. Прогнозное управление локальной городской системой теплоснабжения на основе нейросетевого моделирования // Вестник ЮУрГУ. Серия «Компьютерные технологии, управление, радиоэлектроника». 2019. № 3(47). С. 28–38. DOI: 10.14529/ctcr200303.

4. Перечень подлежащих разработке вопросов

4.1. Описать научные работы по тематике проекта.

4.2. Сформировать архитектуру системы и ее возможности.

4.3. Спроектировать систему.

4.4. Провести тестирование.

4.5. Подготовить экспериментальные результаты.

5. Дата выдачи задания: 07.02.2022 г.

Научный руководитель,
профессор кафедры СП, д.ф.-м.н., доцент М.Л. Цымблер

Задание принял к исполнению Е.А. Латыпова

ОГЛАВЛЕНИЕ

ВВЕДЕНИЕ 5
1. АНАЛИЗ ПРЕДМЕТНОЙ ОБЛАСТИ 8
1.1. Описание предметной области 8
2. ОБЗОР СУЩЕСТВУЮЩИХ РЕШЕНИЙ 12
3. ПРОЕКТИРОВАНИЕ ПРИЛОЖЕНИЯ 17
3.1. Общая архитектура модуля очистки данных 17
3.2. Описание Препроцессора 18
3.3. Функциональные и нефункциональные требования 21
3.4. Варианты использования системы 22
3.5. Диаграмма компонентов для Препроцессора 23
3.6. Диаграмма деятельности для Препроцессора 24
4. РЕАЛИЗАЦИЯ ПРЕПРОЦЕССОРА 26
4.1. Программные средства реализации 26
4.2. Реализация компонентов препроцессора 26
4.3. Описание модульного тестирования препроцессора 29
5. ВЫЧИСЛИТЕЛЬНЫЕ ЭКСПЕРИМЕНТЫ 31
5.1. Набор данных 31
5.2. Проведение экспериментов для алгоритма восстановления 31
5.3. Проведение экспериментов для алгоритма по поиску выбросов 33
ЗАКЛЮЧЕНИЕ 35
ЛИТЕРАТУРА 37
ПРИЛОЖЕНИЯ 41
ПРИЛОЖЕНИЕ А. Спецификация вариантов использования 41
ПРИЛОЖЕНИЕ Б. Свидетельство о государственной регистрации программы для ЭВМ 43

ВВЕДЕНИЕ

Актуальность

Все современные интеллектуальные системы управления отоплением зданий являются комплексом датчиков (например: давления, температуры, расхода), систем мониторинга и управления.

Речь идет о Технологии Интернета вещей (IoT, Internet of Things), которая набирает болящую популярность на данном этапе развития, так как способна максимально автоматизировать работу по обеспечению комфортной жизнедеятельности человека. Дополнительно такие системы позволяет получать большие массивы данных о различных параметрах, влияющих на общие условия в здании. Всесторонний анализ массивов данных IoT систем позволяют своевременно выявлять случаи отклоняющихся значений производительности и показателей энергоэффективности зданий за допустимые пределы. При рассмотрении всей совокупности данных в единой системе увеличение количества источников данных может привести к выполнению некорректного анализа данных в случае сбоя даже одного источника данных [1].

Причиной подобного может служить следующее: износ оборудования, неправильные монтаж и эксплуатация оборудования (человеческий фактор), конструктивные недостатки программного и аппаратного обеспечения, выход условий эксплуатации за пределы допустимых значений, а также многие другие подобные факторы. Для обеспечения эффективной и правильной работы системы, вся некорректная информация должна исправляться [1, 2].

В данной работе представлена часть SCADA-системы ПолиТЭР для управления отоплением, установленной в Южно-Уральском государственном университете, и описана структура и принципы реализации препроцессор Модуля очистки данных, внедренного в указанную систему [3].

В данной работе будет описан препроцессор, основными функциями которого является извлечение необработанных данных из хранилища данных системы и их обработка. Она должна включать: обнаружение аномальных значений и их очистка, восстановление пропущенных данных во временном ряде. Временной ряд должен подвергаться минимальным изменениям, так как препроцессор искажает данные полученные от датчиков. Но это сделано с тем расчетом, чтобы не вносить в последующий этап системы заведомо некорректных данных, возникающих из-за разного рода сбоев. Неточность, вносимая восстановленными данными ниже той, которую вносят сбои.

Постановка задачи

Целью выпускной квалификационной работы является разработака системы препроцессинга данных, входящего в состав модуля очистки данных, для SCADA-системы «ПолиТЭР» для управления отоплением, установленной в Южно-Уральском государственном университете. Для достижения поставленной цели необходимо решить следующие задачи:

1) рассмотреть предметную область;
2) описать научные работы по тематике проекта;
3) сформировать архитектуру системы и ее возможности;
4) смоделировать систему;
5) провести тестирование;
6) подготовить экспериментальные результаты.

Структура и содержание работы

Работа состоит из введения, пяти глав, заключения, списка литературы и двух приложений А и Б. Объем работы соответствует 43 страницам, объем списка литературы составлен из 39 источников. Работа содержит 11 рисунков и 11 листингов. Ниже приведено краткое описание содержимого каждой главы.

В первой главе описана предметная область, архитектура и состав SCADA-системы «ПолиТЭР» для управления отоплением, установленной в Южно-Уральском государственном университете.

Вторая глава посвящена описанию общей концепции подобных систем и приведен анализ предметной области и существующих систем и решений, на основе которых подбирались алгоритмы и подходы, наилучшим образом характеризующие Модуль очистки данных и непосредственно Препроцессор.

В третьей главе приведено описание поставленной задачи, концепции системы Модуля очистки данных и Препроцессора, описание и иллюстрации из архитектур и алгоритмов на которых реализована система. Так же приводятся требования к разрабатываемым программам, которые были определены из разработанной архитектуры и выбранных решений, схема его проектирования: диаграммы вариантов использования, компонентов и деятельности.

Четвертая глава содержит описание реализации системы, конфигурация и ее тестирования.

В пятой главе приведено описания экспериментов, в которых представлены: подбор параметров для работы система и графики работы алгоритма.

В приложениях проиллюстрированы спецификации вариантов использования, описанные в главе 3 и свидетельство и государственной регистрации программы для ЭВМ.

1. АНАЛИЗ ПРЕДМЕТНОЙ ОБЛАСТИ

1.1. Описание предметной области

На рисунке 1 представлена структура интеллектуальной системы управления теплоснабжением зданий кампуса ЮУрГУ. Система состоит из трех уровней. На нижнем уровне система включает в себя различные проводные и беспроводные датчики, приборы учета и контроллеры. На среднем уровне выполняется обеспечение связи контроллеров и узлов учета с сервером баз данных посредством различного проводного и беспроводного сетевого оборудования. Третий уровень включает SCADA-систему «ПолиТЭР» с сервером баз данных, осуществляющую обработку информации. Представление обработанных данных осуществляется на АРМ локальных пользователей через ЛВС ЮУрГУ или на АРМ удаленных пользователей через сеть Интернет [1].

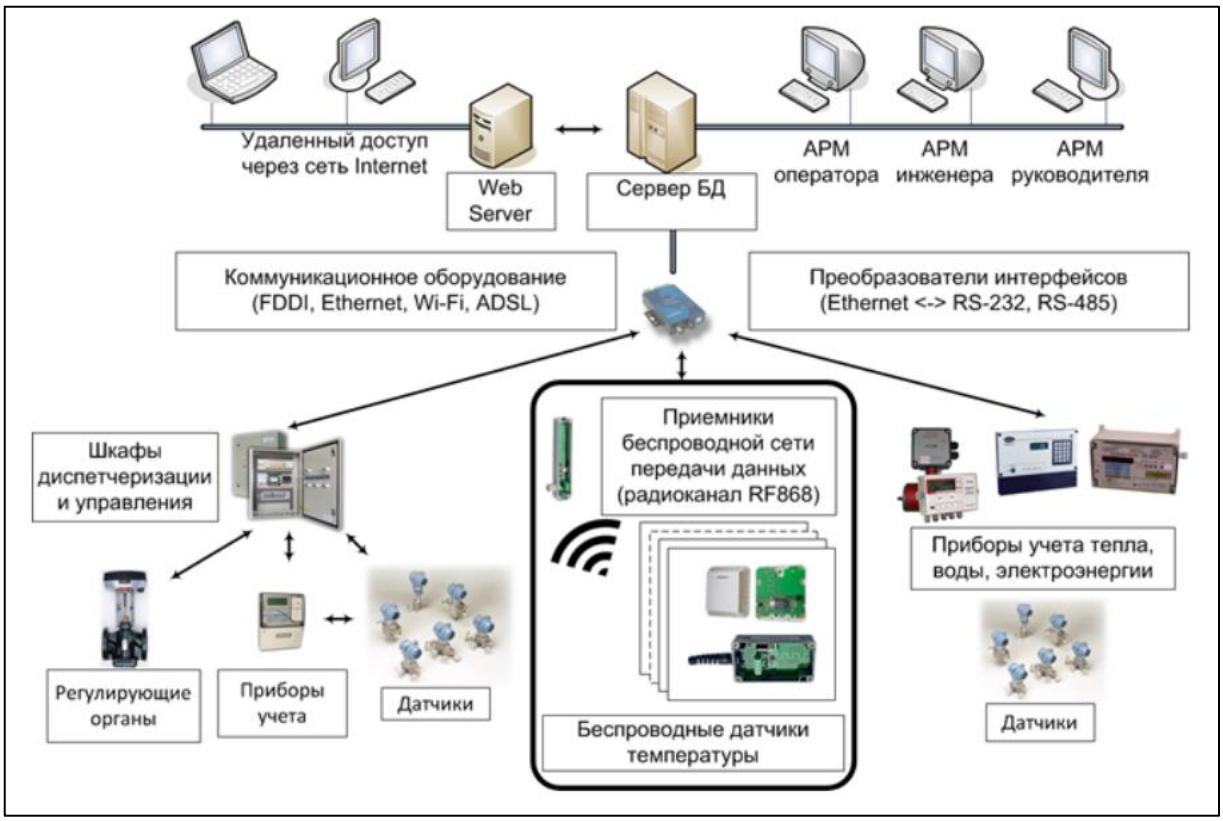

Рисунок 1 – Архитектура SCADA-системы ПолиТЭР

Внедрение данной системы в ЮУрГУ началось в 2010 г. Особое внимание при внедрении данной системы в ЮУрГУ было уделено системе теплоснабжения. Целью внедрения стала комплексная оптимизация процессов управления теплоснабжением и теплопотреблением за счет интеграции территориально распределенного измерительного оборудования с автоматическими системами управления собственными системами.

Интеллектуальной системы управления теплоснабжением зданий включают в себя следующее измерительное и управляющее оборудование:

– узлы учета тепловой энергии (57 шт.), оборудованные тепловычислителем с подключенными к нему 2 датчиками давления, 2 датчиками температуры и 2 расходомерами;

– узлы учета холодной воды (58 шт.), оборудованные вычислителем с подключенными к нему датчиком давления и расходомером;

– узлы учета газа (3 шт.), оборудованные газовым корректором с подключенными к нему расходомером датчиками температуры и давления;

– контроллеры управления распределением тепловой энергии в индивидуальных тепловых пунктах (24 шт.) с подключенными к ним 5 датчиками температуры и различными дискретными датчиками защит, а также управляющими приводами;

– контроллеры управления генерацией и распределением тепловой и электрической энергии (5 шт.) когенерационных установок, газовой котельной и центральных тепловых пунктов с множеством различных датчиков и управляющих устройств;

– беспроводные датчики контроля температурного режима помещений (более 300 шт.).

Программный комплекс ПолиТЭР реализован на языках программирования C++, R и использует Oracle в качестве базовой СУБД.

Поддерживаются открытые и проприетарные протоколы обмена данными с оборудованием различных производителей, конфигурируемая среда визуализации данных, оповещения оператора системы по SMS и электронной почте.

В 2018 г. сенсорная подсистема была существенно расширена IoT-устройствами, позволяющими собирать дополнительную информацию о температурном режиме помещений, что позволило существенно оптимизировать систему отопления зданий. Внедрение интеллектуальной системы управления теплоснабжением зданий в кампусе ЮУрГУ позволило в 2018 г. сэкономить около 15 % тепловой энергии.

Основной проблемой эксплуатации измерительного оборудования является периодическое появление ошибочных показаний или данных с наличием возмущений неизвестного характера. Одной из причин является выход оборудования из строя: ввиду устаревания или нарушения условий эксплуатации оборудования ежегодно 10-20 различных устройств подлежат замене. Другой причиной является засорение областей контакта датчика с измерительной средой. Также периодически возникают обрывы линий связи с контрольно-измерительными устройствами, при этом большинство приборов, в особенности, контроллеры, не поддерживают аппаратные архивы данных. Типичной причиной также является некорректная установка оборудования, приводящая к возникновению дополнительных возмущений, связанных с нетиповыми режимами эксплуатации IoT-датчиков в области их установки.

Некорректные данные приводят к следующим основным проблемам:

– ошибочные вычисления в ходе выполнения оптимизационных алгоритмов, построению некорректных характеристик объектов управления и, как следствие, к некорректному принятию стратегических решений;

– некорректное принятие решений персоналом при наличии недостоверных отклонений параметров эксплуатации от их номинальных значений;

– некорректное автоматическое управление посредством контроллеров может привести не только к перерасходу энергии, но и к выходу из строя инженерных коммуникаций (например, замораживание системы отопления);

– некорректный расчет потребляемых энергоресурсов или наложение энергоснабжающими организациями на потребителя штрафных санкций за несвоевременное обнаружение и устранение неисправностей.

Своевременное обнаружение, устранение неисправностей оборудования и восстановление данных дает существенный организационно-экономический эффект за счет уменьшения или исключения упущенной выгоды при возникновении указанных проблем.

В описываемом исследовании предложен Модуль очистки данных, расширяющий систему ПолиТЭР и решающий следующие основные задачи:

– оперативное обнаружение аномального поведения датчиков температуры и уведомление оператора о найденных аномалиях;

– оперативное обнаружение пропусков и выбросов в измеряемых данных датчиков и замена таких значений на синтетические правдоподобные данные.

Модуль очистки данных должен располагается в системе ПолиТЭР между уровнем считывания данных и уровнем их использования для аналитических расчетов и представления. При этом отображаемые данные отмечаются как исходные или восстановленные, а доступ к некорректным данным сохраняется для возможности их более глубокого анализа.

2. ОБЗОР СУЩЕСТВУЮЩИХ РЕШЕНИЙ

Обнаружению выбросов посвящено множество различных методик, многие из которых используются в теории обнаружения отказов оборудования [4]. К базовым подходам относятся методы, определяющие выход за границы допустимого диапазона отклонения фактических значений от значений, рассчитанных по модели объекта [5, 6].

В работе [7] на примере систем мониторинга вентиляции и кондиционирования для определения некорректных показаний используется сочетание трех способов обработки данных: уменьшение размерности коррелирующих данных, сигнализирующих о возникновении выбросов; применение расширенного фильтра Калмана для фильтрации шумов и разложения данных во временные ряды; разделение областей корректных и некорректных значений статических и динамических параметров модели объекта с использованием рекурсивного одноклассового метода опорных векторов.

В работе [8] рассматривается задача прогнозного управления теплоснабжением потребителей с помощью нейросети, обученной на статистических данных, получаемых с подсистемы мониторинга. Искусственная нейронная сеть рассматривается в качестве основного инструмента, минимизирующего ошибки, связанные с ручным управлением температурой на выходе из котельной.

Исследование подходов к сбору и анализу данных на предприятиях водоснабжения и водоотведения рассмотрены в работе [3].

Для определения отклонений в работе систем централизованного теплоснабжения в работе [9] предлагается применять метод ближайшего соседа. В данной работе в качестве эталона берутся параметры работы группы схожих автоматизированных индивидуальных тепловых пунктов (АИТП). Неисправностями считаются отклонения показателей работы одного АИТП от показателей группы схожих с ним АИТП, подключенных

к одной системе централизованного теплоснабжения, на величину заданного порога.

В работе [10] представлено применения метода главных компонент для идентификации выбросов в данных работы систем отопления, вентиляции и кондиционирования. В работе [11] описан метод восстановления данных, применяемый совместно с методом главных компонент.

Также стоит отметить метод построения балансовых моделей, применяемый к связанным теплоэнергетическим комплексам. Расхождение энергетического или гидравлического баланса в таких моделях свидетельствует о наличии неисправностей в системе или о наличии выбросов [12].

Восстановление данных, утраченных при возникновении выбросов, выполняется путем их расчета на базе методов прогнозирования. Множество работ посвящено прогнозированию параметров систем теплоснабжения с использованием статических и динамических факторных моделей и моделей временных рядов с идентификацией методами авторегрессионного анализа [13], метода опорных векторов [14] и рекуррентных нейронных сетей [15].

Также интерес представляет подход к восстановлению статических и динамических характеристик моделей, искажение которых возникает в результате периодических возмущений. Учет подобных возмущений выполняется путем описания их времени действия индикаторными функциями [16].

Простые методы восстановления данных [17] заключаются в расчете и подстановке вместо пропущенного среднего значения до и после пропуска или присвоении пропущенному – значения предыдущего. Но при таком подходе, при больших промежутках отсутствующих значений, восстановление не будет иметь достаточную точность, так как весь участок

будет заменен прямой линией. В работе [18] рассматриваются методы восстановления данных временных рядов, основанные на нейронных сетях, которые решали проблему с восстановлением обширных промежутков. Авторы в работе [17] представляют метод вычисления в контексте алгоритмов машинного обучения и представляют метод вычисления k-ближайшего соседа (kNNI) для восстановления пропущенных значений. Для объекта с несколькими атрибутами, у которого отсутствует значение для одного атрибута, подход kNNI ищет k объектов с аналогичными значениями для других атрибутов в соответствии с метрикой расстояния.

Модель ARIMA [19] – это популярная модель прогнозирования временных рядов, которая является обобщением модели авторегрессии (AR). ARIMA использует структурные методы анализа временного ряда, ориентированные на оценку параметров будущих значений от известных прошлых значений временного ряда при дополнительных предположениях о свойствах наблюдаемых величин.

Авторы работы [20] для восстановления блоков пропущенных значений предлагают алгоритм REBOM для нерегулярных временных рядов. Алгоритм строит матрицу, в которой хранятся временной ряд с пропущенными значениями и n наиболее линейно коррелированных временных рядов в соответствии с корреляцией Пирсона. В следующей работе [21] они представляют решение с линейной пространственной сложностью, основанное на центроидной декомпозиции (CD), которое является приближением SVD. Этот алгоритм предполагают линейную корреляцию между подпоследовательностью временного рядя и опорных временных рядов. Если временные ряды не коррелированы линейно, точность восстановления ухудшается.

DynaMMo [22] используется для анализа, классификации и расчета временных рядов, взятых из систем захвата движений человека. Он основан на фильтрах Калмана, которые, как и SVD, предполагают

линейную корреляцию между временными рядами для точной оценки неизвестных значений. Алгоритм допускает использование только одного опорного ряда, этого часто недостаточно для точного восстановления.

MUSCLES [23] – это онлайн-алгоритм, основанный на многомерной модели авторегрессии, параметры которой постепенно обновляются с использованием метода рекурсивных наименьших квадратов. Помимо прошлых значений неполных временных рядов, MUSCLES также учитывает самые последние значения совместно развивающихся и линейно коррелированных временных рядов, которые находятся в пределах скользящего окна. Поскольку небольшие неточности восстановления накапливаются в течение длительного периода пропущенных значений, точность MUSCLES ухудшается.

SPIRIT [24, 25] – алгоритм, использующий онлайн-анализ главных компонентов (PCA), чтобы сократить набор из n совместно развивающихся и коррелированных потоков до небольшого числа k скрытых переменных, которые суммируют наиболее важные тенденции в исходных данных. Для каждой скрытой переменной SPIRIT соответствует одной модели AR для прошлых значений, которая постепенно обновляется по мере поступления новых данных. Если значение отсутствует, модели AR используются для прогнозирования текущего значения каждой переменной, из которого выводится оценка отсутствующего значения. Обновление моделей с использованием восстановленных данных вызывает те же проблемы, что и MUSCLES, поскольку распространяются неточности. Поскольку PCA и SVD основаны на одном и том же базовом принципе, слабые стороны PCA совпадают с SVD для восстановленных временных рядов.

При этом необходимо отметить, что особенностью эксплуатационных данных систем теплоснабжения является периодический характер, связанный с цикличностью изменения погодных условий и режимов эксплуатации помещений в зависимости от времени

суток. Выбросы в эксплуатационных данных, возникающие при работе различных подсистем, связанных с теплоснабжением, характеризуются резким изменением измеряемого сигнала, длящимся в пределах ограниченного периода времени.

В полной системе было решено использовать сочетание нескольких подсистем: Препроцессор (о котором пойдет речь далее), Предиктор, и Реконструктор.

В данной работе пойдет описание Препроцессора, который включает в себя: поиск и удаление кратковременных аномалия и восстановление данных, которые были утеряны датчиками или в результате работы очистки от выбросов (удаления кратковременных аномалий). Это может обеспечить очень хороший результат дальнейшей работы системы. Так как при краткосрочных сбоях подготовить качественную обучающую выборку является одной из первостепенных задач. Нейронные сети, обучающиеся на засоренных данных, могут показать некачественный выходной результат, что при прогнозировании может внести больше неточности в работу. Это могут исправить синтетические встроенные в ряд значения после алгоритмов восстановления временного ряда и удаления из него выбросов, представленные далее в этой работе.

3. ПРОЕКТИРОВАНИЕ ПРИЛОЖЕНИЯ

3.1. Общая архитектура модуля очистки данных

Общая архитектура Модуля очистки данных представлена на рисунке 2. Модуль тиражируется для каждого температурного датчика системы ПолиТЭР и состоит из следующих основных подсистем: Препроцессор, Предиктор, Реконструктор и Детектор аномалий. Препроцессор подготавливает накопленные показания датчиков для дальнейшей обработки. Предиктор обеспечивает искусственную нейронную сеть, которая выполняет прогноз следующего значения датчика на основе его исторических данных. Реконструктор определяет, является ли текущее показание датчика выбросом, и в этом случае заменяет его на синтетическое значение, полученное Предиктором. Детектор аномалий обнаруживает аномальные подпоследовательности в показаниях датчика для последующего уведомления оператора системы ПолиТЭР.

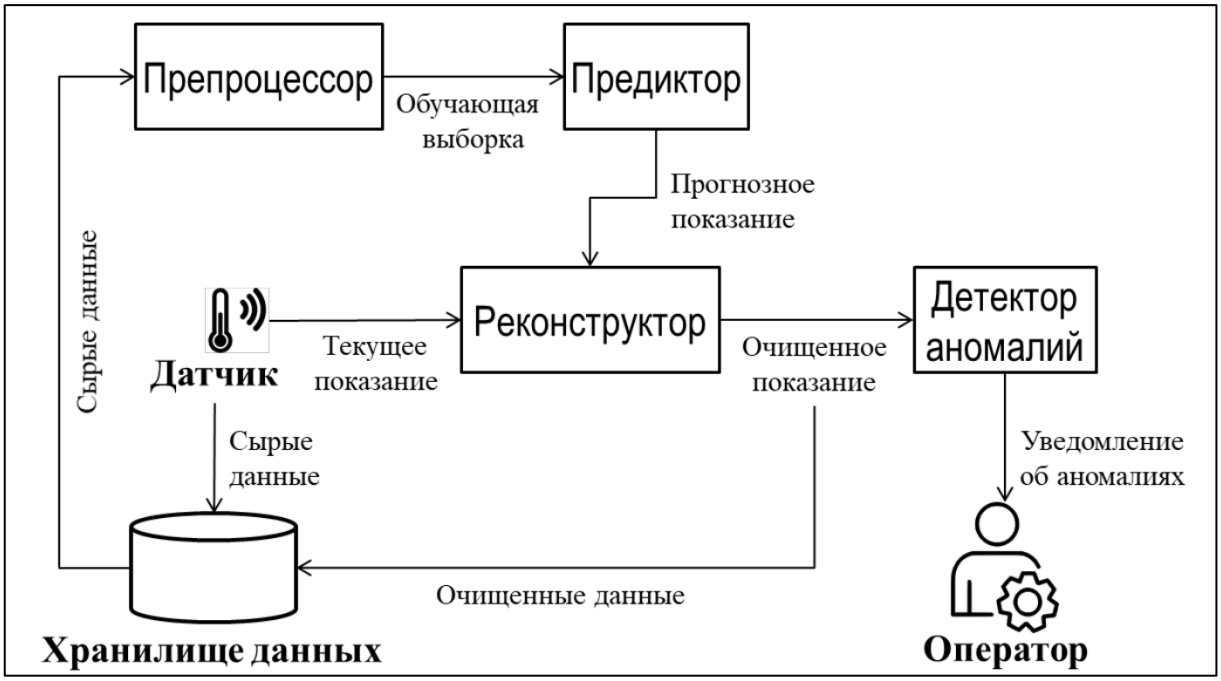

Рисунок 2 – Архитектура Модуля очистки данных

Технологический цикл Модуля очистки данных для некоторого датчика выглядит следующим образом. Препроцессор выполняет свои

действия регулярно с частотой, определяемой оператором системы (типичным случаем является запуск Препроцессора один раз в месяц). Препроцессор извлекает из хранилища данных неочищенные показания датчика, накопленные к текущему моменту, и подготавливает обучающую выборку для нейронной сети подсистемы Предиктор.

Предиктор запускается регулярно, но в соответствии с частотой снятия показаний датчика (например, один раз в 15 минут), и выполняет следующие действия. Нейронная сеть прогнозирует текущее значение датчика. Если при этом датчик не снял показание, то оно заменяется на прогнозное. Иначе подсистема Реконструктор выполняет бинарную классификацию значения, полученного от датчика: выброс или норма. Если текущее значение распознается как выброс, Реконструктор заменяет текущее значение на спрогнозированное. Модуль очистки данных передает спрогнозированные значение системе для сохранения в хранилище данных.

В завершении цикла Детектор аномалий определяет, завершает ли текущее значение датчика некоторую аномальную последовательность значений датчика, и уведомляет оператора системы в этом случае.

Далее Препроцессор рассмотрен более подробно.

3.2. Описание Препроцессора

Препроцессор выполняет подготовку обучающей выборки для нейронной сети подсистемы Предиктор и состоит из следующих основных подсистем: Парсер, Восстановитель, Детектор выбросов и Нормализатор. Технологический цикл работы Препроцессора представлен на рисунке 3.

Сначала Парсер извлекает данные датчика из хранилища данных и преобразует их в формат, пригодный для последующей обработки. Затем Восстановитель заменяет пропущенные значения на правдоподобные синтетические. После этого Детектор выбросов находит в данных точки-

выбросы и заменяет их пустыми значениями «NULL». Полученные данные повторно подаются на вход Восстановителя, который, таким образом, заменяет выбросы на правдоподобные (синтетические) значения. На последнем шаге Нормализатор формирует из полученных данных набор нормализованных подпоследовательностей, которые являются обучающей выборкой для нейронной сети подсистемы Предиктор.

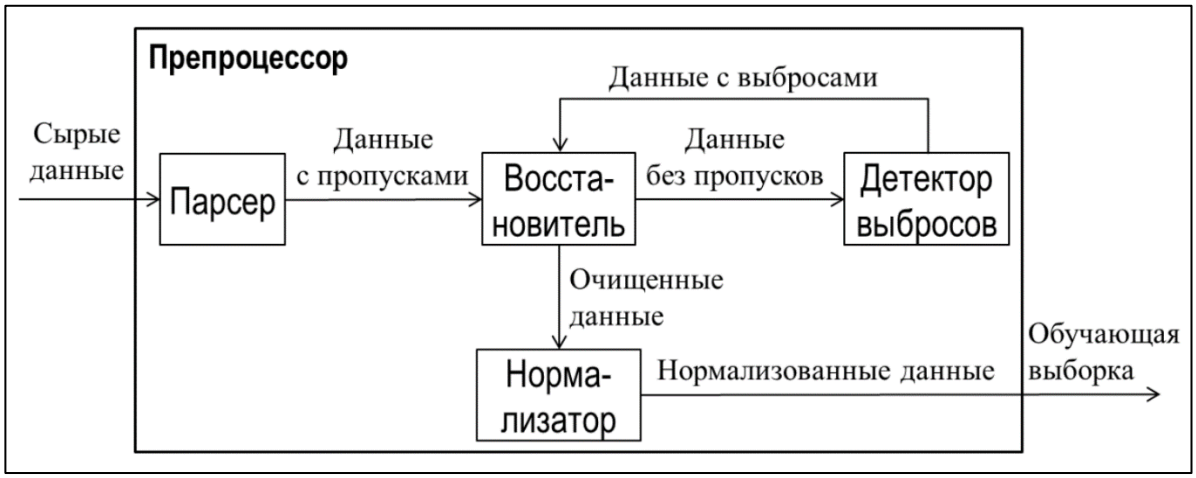

Рисунок 3 – Архитектура Препроцессора

Восстановитель использует сезонную авторегрессионную интегрированную модель скользящего среднего с эксогенными регрессорами SARIMAX (Seasonal AutoRegressive Integrated Moving Average with exogenous regressors) [26], которая часто применяется для прогнозирования значений сезонных временных рядов в различных предметных областях. Свойство сезонности временного ряда подразумевает наличие в данном ряде колебаний, возникающих с некоторой периодичностью. Для применения SARIMAX в данной предметной области необходимо подобрать следующие параметры: p – порядок авторегрессии, d – порядок интегрирования, q – порядок скользящего среднего, P – сезонный порядок авторегрессии, D – порядок сезонного интегрирования, Q – сезонный порядок скользящего среднего, s – период сезонности временного ряда. Применение SARIMAX

возможно, если целевой временной ряд является стационарным. Под стационарными временными рядами понимают такие временные ряды, элементы которых являются случайными величинами с постоянным математическим ожиданием и постоянной дисперсией. Стационарность временного ряда проверяется с помощью следующих двух тестов, применяемых последовательно: расширенный тест Дики-Фуллера (ADF) [27] и тест Квятковского-Филлипса-Шмидта-Шина (KPSS) [28]. Если указанные тесты не подтвердят стационарность временного ряда, то для применения модели SARIMAX необходимо преобразовать элементы ряда в зависимости от его характеристик, например, логарифмировать элементы в случае наличия в ряде мультипликативной сезонности (существенного отличия дисперсии элементов в различных участках ряда).

В более формальном изложении работа Препроцессора выглядит следующим образом. Парсер извлекает из хранилища данных временной ряд T, который представляет собой хронологически упорядоченную последовательность числовых либо пустых значений: $T_{i,n}=(t_1, \cdots, t_m)$, где $t_i \in R$ или $t_i = Null$ и число m называется длиной временного ряда. Затем тандем Восстановителя и Детектора выбросов преобразует T таким образом, чтобы $\forall i \ t_i \in R$.

Далее Нормализатор подготавливает обучающую выборку, каждый элемент которой представляет собой пару «последовательность показаний датчика» и «прогнозное значение датчика». В качестве первого элемента указанной пары берется нормализованная подпоследовательность показаний датчика фиксированной длины, в качестве второго элемента – одно нормализованное показание датчика, следующее за данной подпоследовательностью.

Подпоследовательностью $T_{i,n}$ временного ряда T назовем непрерывный промежуток значений указанного ряда, состоящий из

n элементов и начинающийся с позиции i : $T_{i,n}=(t_1,\cdots, t_{i+n-1})$, $1 \le i \le m-n+1$. Используя минимаксную нормализацию, для подпоследовательности $T_{i,n}$ ее нормализованная версия $\widetilde{T}_{i,n}$ вычисляется как $\widetilde{T}_{i,n}=(\widetilde{t}_1,\cdots, \widetilde{t}_{i+n-1})$, где $t_i=\frac{t_i-t_{min}}{t_{max}-t_{min}}$. Для нормализованной подпоследовательности $\widetilde{T}_{i,n}$ элемент $\widetilde{t}_1$ рассматривается как ее прогнозное значение. Для дальнейшего использования введем обозначение S_T^n набора нормализованных подпоследовательностей временного ряда T, имеющих длину $n\,(n \ll m)$, и за P обозначим набор соответствующих этим подпоследовательностям прогнозов.

Длина подпоследовательности n ($n \ll m$) является параметром Модуля очистки и вычисляется как $n = frequency \times horizon$, где $frequency$ – частота датчика, а $horizon$ – исторический горизонт (длина временного интервала в прошлом), используемый Предиктором и подбираемый оператором SCADA-системы «ПолиТЭР». Например, типичная частота снятия показаний температурного датчика 4 раза в час, исторический горизонт выбран равным 12 часам, тогда длина подпоследовательности, используемая Модулем очистки, составляет $n = 48$.

3.3. Функциональные и нефункциональные требования

Функциональные требования – это требования, которые определяют действия, которые должна выполнять система, без учета ограничений, связанных с ее реализацией, то есть определяют поведение системы в процессе обработки информации. Из приведённого выше описания отметим основные требования к системе.

Система должна:

1) загрузить данные из внешнего источника и приводить их к удобному для обработки виду;

2) возвращать данные обучающей выборки;

3) восстанавливать показания, которые имеют значение NULL;

4) находить данные, считающиеся кратковременными выбросами (определим их как 1-3 значения, имеющие значительное отличие от последовательности) и присваивать им значение NULL;

5) нормализовать весь временной ряд.

Нефункциональные требования – это требования, которые не определяют поведение системы, но описывают атрибуты системы или атрибуты системного окружения.

При описании системы было выявлено основное нефункциональное требование – система должна иметь ошибку восстановления не менее 0,2, рассчитанная по RMSE (среднеквадратическая ошибка).

3.4. Варианты использования системы

Для проектирования приложения был использован язык графического описания для объектного моделирования UML.

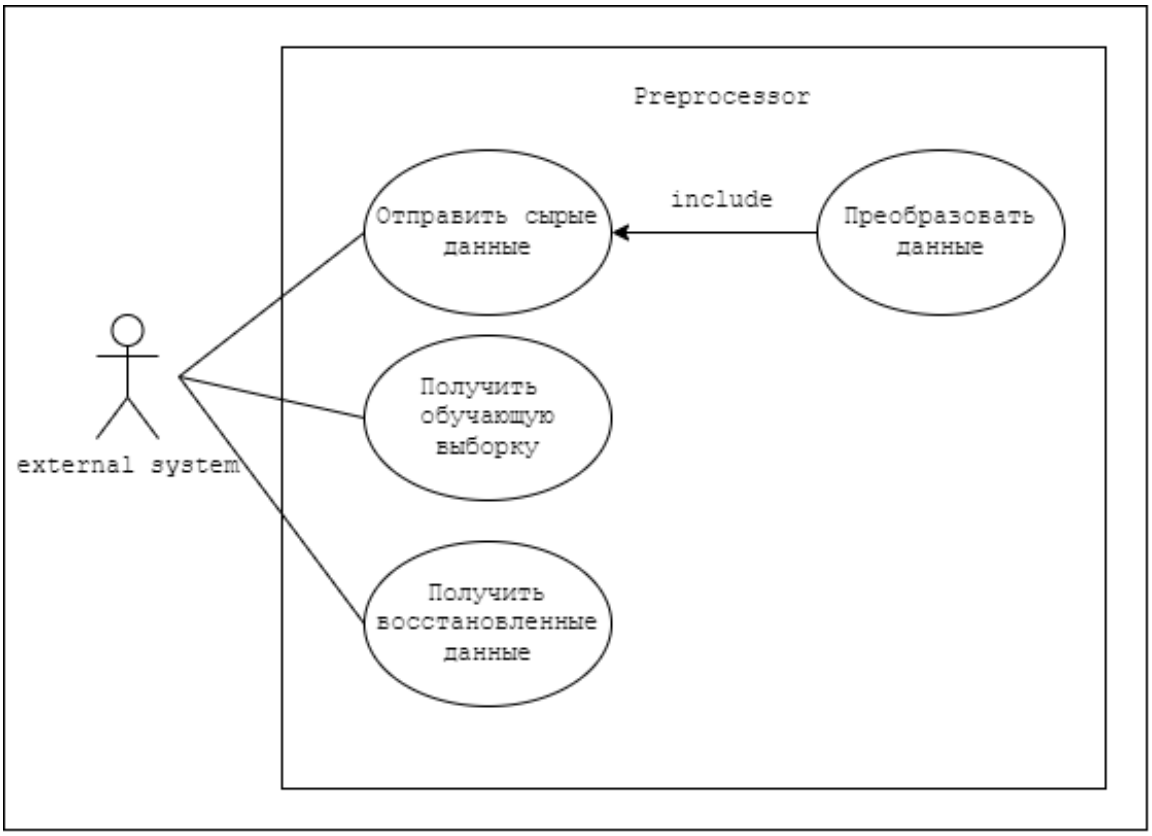

Рисунок 4 – Диаграмма вариантов использования

Была построена модель взаимодействия актера «Внешняя система» («external system») с Препроцессором. Диаграмма вариантов использования (use-case diagram) представлена на рисунке 4.

Актером является внешняя система (external system) на представленной диаграмме, которая имеет четыре основных варианта использования системы:

1) отправить сырые данные;
2) получить обучающую выборку;
3) получить восстановленные данные;
4) прецедент преобразовать данные, который включается в первый в перечислении вариант использования.

Спецификация вариантов использования, представленных на рисунке 3, приведена в приложении А.

3.5. Диаграмма компонентов для Препроцессора

В данном разделе рассматривается разработанная диаграмма компонентов, которая показывает разбиение системы на структурные компоненты и связи между ними. Разработанная диаграмма представлена на рисунке 5.

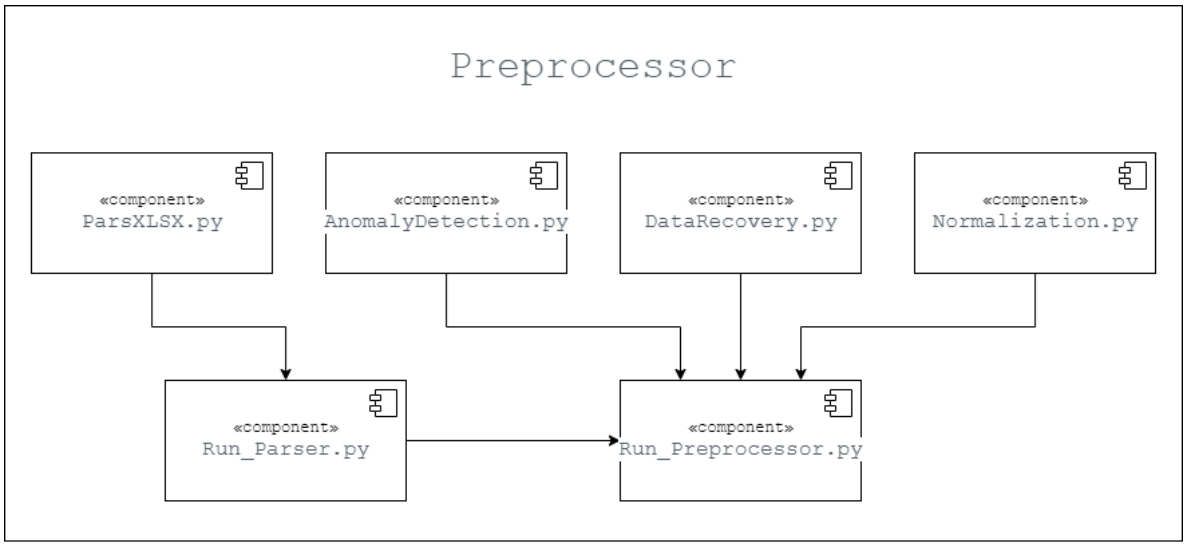

Рисунок 5 – Диаграмма компонентов

Данная диаграмма состоит из следующих компонентов:

1) `ParsXLSX.py` – экспортирует функцию чтения и парсинга данных из файла формата *.xlsx, с параметрами настраивающими парсер в зависимости от структуры файла;

2) `AnomalyDetection.py` – экспортирует функцию для поиска точечных аномалий (выбросов);

3) `DataRecovery.py` – экспортирует функцию для восстановления пропущенных значений;

4) `Normalization.py` – экспортирует функцию нормализации данных;

5) `Run_Parser.py` – выполняет функцию чтения и парсинга данных из файла формата *.xlsx, формирует директорию и наполняет ее в зависимости от наполнения в файла (лист файла – каталог в директории, столбец – файл *.csv);

6) `Run_Preprocessor.py` – выполняет функции чтения заданного файла, прессинга данных, поиска точечных аномалий (выбросов), восстановления пропущенных значений и нормализации временного ряда.

3.6. Диаграмма деятельности для Препроцессора

В соответствии с требованиями, которые предоставлены выше в разделе, реализована диаграмма деятельности, показывающая, как происходит процесс взаимодействия внешней системой и препроцессорам. На рисунке 6 реализована диаграмма деятельности.

В представленной диаграмме внешняя система обращается к функциям Препроцессора.

Система отправляет команду на считывание файла. В соответствии с установленными конфигурационными параметрами, Препроцессор стартует парсинг, которой проверяет корректность данных, и их целостность. Если данные корректны и в них присутствуют пропуски и

выбросы, запускается преобразование данных. Результат преобразования возвращается только после завершения работы Препроцессора по очистке от выбросов и восстановлению данных, которые записываются в файл формата *.csv. Затем запускается нормализация, которая формирует, как и в предыдущем шаге *.csv, но с пометкой `normalized`.

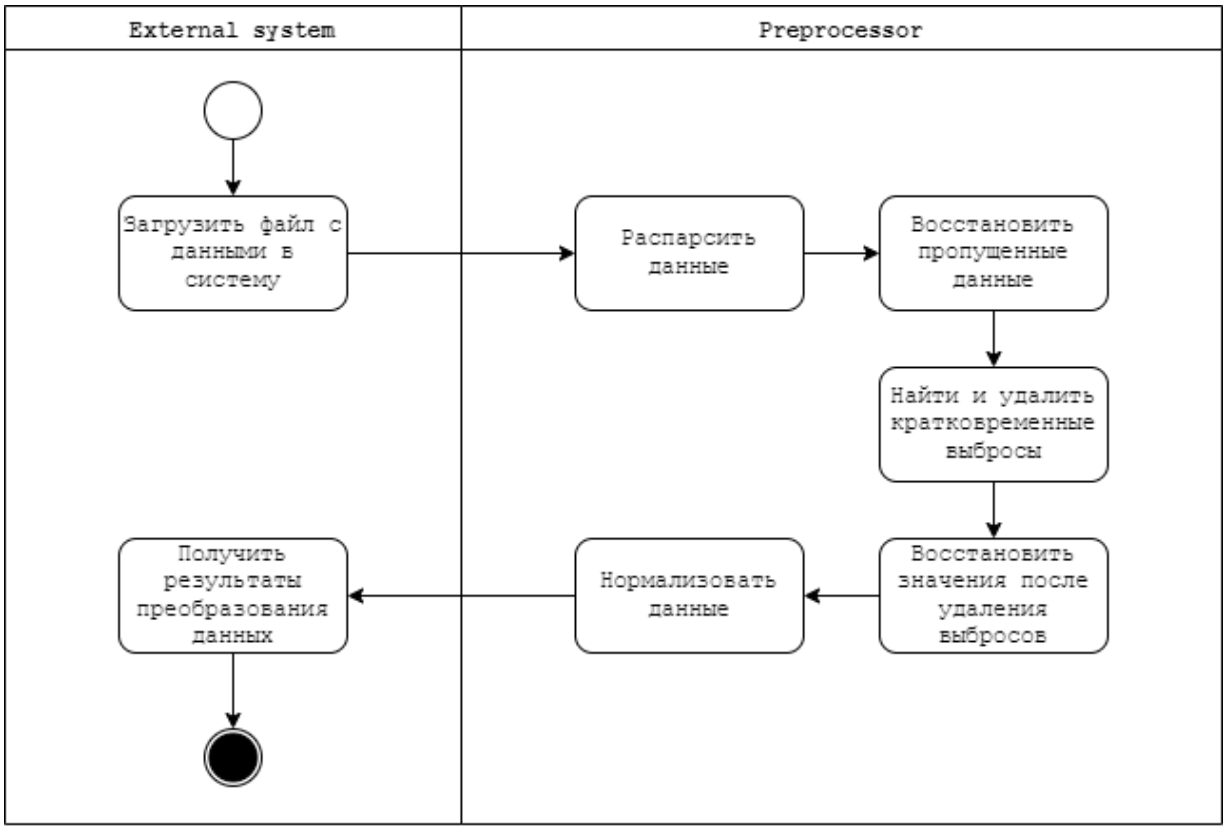

Рисунок 6 – Диаграмма деятельности

После всего преобразования внешняя система может пользоваться данными, которые были получены в результате работы Препроцессора, что соответствует действию «Получить результаты преобразования данных».

4. РЕАЛИЗАЦИЯ ПРЕПРОЦЕССОРА

4.1. Программные средства реализации

Препроцессор реализован с помощью библиотек языка Python версии 3.9 [29] (не менее 3.5) следующим образом. Парсер использует стандартные библиотеки openpyxl версии 3.0.10 [30] и pandas версии 1.3.6 [31]. Детектор выбросов основан на алгоритмах библиотеки adtk версии 0.6.2 (Anomaly Detection Toolkit) [32]. Модель SARIMAX, используемая Восстановителем, реализована в стандартной библиотеке statsmodels версии 0.13.2 [33]. Нормализатор реализован с помощью стандартной библиотеки sklearn версии 1.1.1 [34]. Так же испоьзовались библеотеки: numpy [35] версии 1.18.4, matplotlib [36] версии 3.1.1 и unittest [37] версии 3.7 для проведения тестирования.

4.2. Реализация компонентов препроцессора

Содержит три основных модуля:

1) `ParsXLSX`;
2) `AnomalyDetection`;
3) `DataRecovery`;
4) `Normalization`.

Для выполнения поставленных задач необходимо установить дополнительные пакеты Python.

Установка пакета statsmodels осуществляется через командную строку (cmd) системы: представленные в листинге 1.

Листинг 1 – Подготовке к и установке пакета statsmodels

```
git clone git: //github.com/statsmodels/statsmodels.git
cd statsmodels
python setup.py build
python setup.py install
```

Далее установить остальные библиотеки командой, представленной в листинге 2.

Листинг 2 – Установка пакетов для python

```
pip install adtk, numpy, pandas,
pip install sklearn, openpyxl, matplotlib, unittest
```

Для выполнения, когда необходимо просмотреть данные из файла config.py. Этот файл содержит основные параметры необходимые для работы системы, а также их детальное описание. Вид этого файла приведен в листингах 3-8. Для описания значений каждой переменой были использовании комментарии.

Листинг 3 – Конфигурация для описания путей в препроцессоре

```
# имя файла или путь к файлу XLSX - excel
file_name_xlsx = 'Данные BIM_BEM 3БВ.xlsx'
# обязательное указывание расширения

# имя папки для сохранения данных в формате CSV и
# называние файла, содержащего имена страниц
save_directory_CSV = 'SensorData'
root_file_name = 'page_names.csv'
# обязательное указывание расширения

# файл с путями к данным с временными рядами
path_time_siries = 'pathFileSensors.csv'
```

Из листинга видно, что для работы системы необходимо указать путь к файлу, из которого будут считываться и преобразовываться данные.

Листинг 4 – Выбор алгоритма поиска аномалий

```
# Выбор метода дедукции аномалий
# 0 - SearchOutliersADTK() - метод поиска аномалий ADTK
# 1 - SearchOutliersMedian() - Поиск выбросов
anomaly_detect = 1
```

Для работы было реализовано два алгоритма `searchOutliersADTK()` – метод поиска аномалий с фильтрацией по группам, который позволяет с помощью группировки оценить является ли данная точка выбросом. `searchOutliersMedian()` – поиск выбросов по медианному значению, когда аномальной точкой считается та, чье отклонение заведомо больше медианного значения.

Листинг 5 – Характеристика алгоритмов поиска выбросов для алгоритма searchOutliersADTK()

```
# Детекция аномалий
#
# SearchOutliersADTK(time_siries, freq=365, c=7.0, n = 3)
#   freq - сезонная вариативность, число от 12 до
#                        len(time_siries)/2. Default: 365
#   side - изменение перепада
#       “both” - в обе стороны;
#       “positive” - возрастание
#       “negative” - убывание
#   c - коэффициент изменяемости выброса.  Default: 7.0
#   n - фильтр точечной аномалии
#(выбросом считать то количество точек подряд, которое меньше n)

SearchOutliersADTK_freq = 365
SearchOutliersADTK_c = 7.0
SearchOutliersADTK_n = 3
```

Листинг 6 – Характеристика алгоритма восстановления пропущенных значений

```
# Восстановление пропущенных значений
#
#   order:
#   d - должно быть целым числом, указывающим порядок
# интегрирования процесса Default: 1,
#   p, q - могут быть либо целыми числами, указывающими
# порядки AR и MA,
# либо итерациями, дающими определенный AR и / или MA
# Default: p = 2, q = 4

order_d = 1
order_p = 2
order_q = 4

# seasonal_order:
#
#   D - должно быть целым числом, указывающим порядок
# интегрирования процесса Default: 1
#   P, Q - могут быть либо целыми числами, указывающими
# порядки AR и MA, либо итерациями,
#          дающими конкретные AR и / или MA
#          Default: p = 2, q = 3
#   s - целое число, задающее периодичность
# (количество периодов в сезоне),
# часто оно равно 4 для квартальных данных
#       или 12 для месячных данных и т.д

seasonal_order_D = 1
seasonal_order_P = 2
seasonal_order_Q = 3
seasonal_order_s = 12
```

Листинг 7 – Характеристика алгоритмов поиска выбросов для алгоритма searchOutliersMedian()

```
# SearchOutliersMedian(time_siries, c=3, dev=0.02):
#   c - коэффициент изменяемости выброса.  Default: 3.0
#   dev - поправочный коэффициент вариативности
# (зависит от среднего значения датчика)
# Выходные данные:
#   outlier - pd.DataFrame(),
# формата: Datetime;
# value(True - аномалия, False - отсутствие аномалии)
SearchOutliersMedian_c = 3.0
SearchOutliersMedian_dev = 0.02
```

Листинг 8 – Пути для тестовых данных

```
# AnomalyDetection
name_file_AnomalyDetectionData =
r"Tests\Data\Anomaly\Data\ec2_cpu_utilization_5f5533.csv"
name_file_AnomalyDetectionTest =
r"Tests\Data\Anomaly\Labels\ec2_cpu_utilization_5f5533Test.csv"
# DataRecovery
name_file_DataRecoveryData = r"Data\Predict\Train1.csv"
name_file_DataRecoveryTest = r"Data\Predict\Test1.csv"
```

Данный конфигурационный файл позволяет отлаживать работу препроцессора, проводить эксперименты и анализ для поиска наиболее подходящих значений для алгоритмов.

Для запуска препроцессора был разработан специальный пусковой файл, который содержит в себе вызовы реализованных компонентов системы в хронологическом порядке (был описан в предыдущей главе в пункте 3.5).

4.3. Описание модульного тестирования препроцессора

Тесты, используемые для проверки системы, распределены по четырем файлам, каждый из которых выполняет тестирование одного компонента из архитектуры препроцессора, представленного на рисунке 3. И имеют следующие названия файлов:

1) `AnomalyDetectionTest.py`;
2) `DataRecoveryTest.py`;
3) `ParsXLSXTest.py`;

4) `NormalizationTest.py`.

Каждый из этих файлов тестирует все экспортируемые функции из одноименных модулей препроцессора.

`AnomalyDetectionTest.py` тестирует экспортируемые функции `AnomalyDetection.py`.

Данные для этой функции представлены в листинге 10, а выходные ожидаемые данные в листинге 11, где:

– 1.0 – аномалия;

– 0.0 – отсутствие аномалии.

Листинг 10 – Входные данные для тестирования функции `AnomalyDetection()`

```
Datetime,value
 2014-04-07 01:50:00,19.6866160273
 2014-04-07 01:55:00,19.3563053672
 2014-04-07 02:00:00,20.4140421657
 2014-04-07 02:05:00,18.8776063185
```

Листинг 11 – Выходные данные тестирования функции `AnomalyDetection()`

```
Datetime,value
 2014-04-07 01:50:00;0.0
 2014-04-07 01:55:00;0.0
 2014-04-07 02:00:00;1.0
 2014-04-07 02:05:00;0.0
```

Тестирование `DataRecovery`, `Normalization` и `ParsXLSX` происходит за счет проверки на небольшом наборе данных, с заранее рассчитанным результатом, который проверяет основные позитивные и негативные (например, не консистентные донные) кейсы.

5. ВЫЧИСЛИТЕЛЬНЫЕ ЭКСПЕРИМЕНТЫ

5.1. Набор данных

Для оценки предложенного подхода были проведены вычислительные эксперименты на реальных данных, взятых из хранилища данных SCADA-системы «ПолиТЭР». В качестве данных использовались показания температурного датчика, установленного в аудитории для потоковых лекций, за 2018 г. (частота снятия показаний датчика составляет 4 раза в час).

После обработки указанных данных Препроцессором первые 42 недели года (80%) показаний были использованы в двух качествах: как выборка для подбора параметров модели SARIMAX Восстановителя. Оставшиеся 8 недель года (20 %) показаний датчика моделировали работу модуля очистки данных в штатном режиме и использовались в качестве тестовой выборки.

5.2. Проведение экспериментов для алгоритма восстановления

Для проверки точности и корректности работы алгоритма восстановления были подобраны параметры для модели SARIMAX [2]:

- порядок авторегрессии $p \in [0, 7]$;
- порядок интегрирования $d = 1$;
- порядок скользящего среднего $q \in [0, 7]$;
- сезонный порядок авторегрессии $P = 1$;
- порядок сезонного интегрирования $D = 1$;
- сезонный порядок скользящего среднего $Q = 0$;
- период сезонности временного ряда $s = 96$.

Что позволило получить максимальную точность работы восстановления данных в Препроцессоре.

На рисунке 7 представлен график прогноза на один день, полученный с помощью модели `SARIMAX(6,1,5)(0,1,1)96` на датчиках в

разных аудиториях, но в один промежуток времени, а на рисунке 8 прогноза на один день полученной на одном датчике в разный период времени.

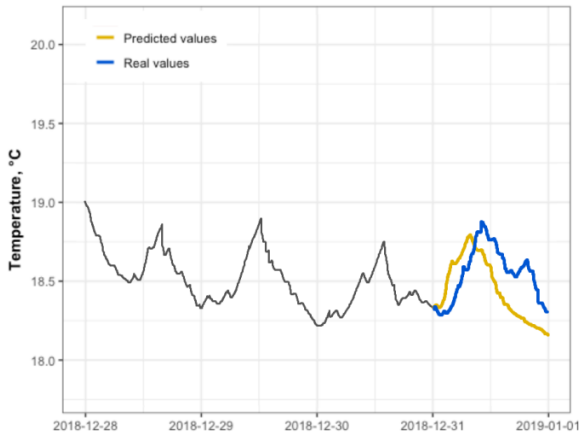

а) аудитория 113

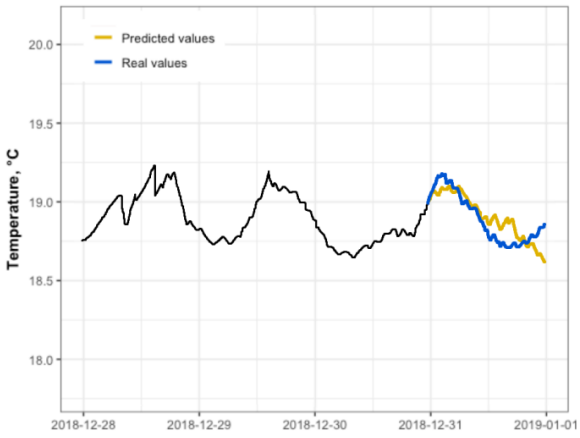

б) аудитория 133

Рисунок 7 – Прогноз на один день, полученный с помощью модели `SARIMAX(6,1,5)(0,1,1)96` для разных аудиторий

По представленным графикам выше была рассчитана среднеквадратичная ошибка: а) RMSE = 0,183, б) RMSE = 0,112.

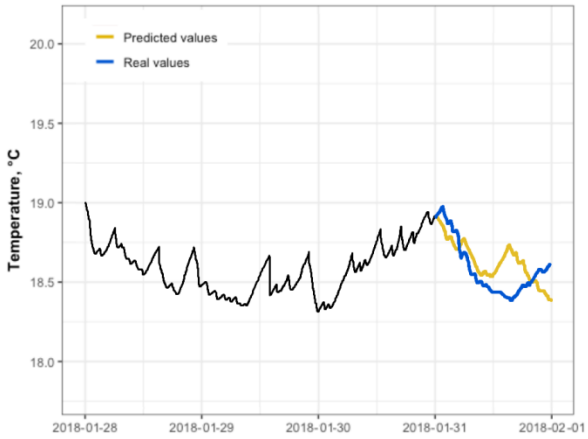

а) прогноз на 31.01

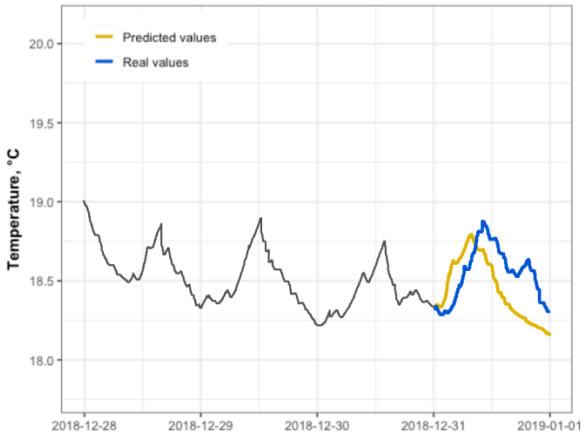

б) прогноз на 31.12

Рисунок 8 – Прогноз на один день, полученный с помощью модели `SARIMAX(6,1,5)(0,1,1)96` для двух промежутков времени

По представленным графикам выше была рассчитана среднеквадратичная ошибка: а) RMSE = 0,116, б) RMSE = 0,121.

На рисунке 9 представлен прогноз на один день, а также построены 80% и 95% доверительные интервалы прогноза. Средняя ошибка прогноза на наборе данных при проведении многочисленных экспериментов (более 10 датчиков температуры, при восстановлении трех различных участков для одного) составляет по мере RMSE = 0,129, что соответствует требованиям, указанным в пункте 3.3 данной работы (RMSE не более 0,2).

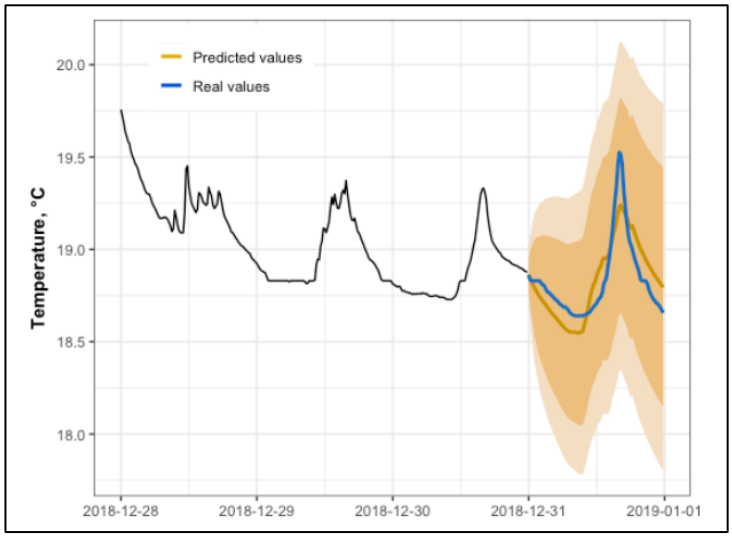

Рисунок 9 – Прогноз на один день, полученный с помощью модели `SARIMAX(6,1,5)(0,1,1)96`

5.3. Проведение экспериментов для алгоритма по поиску выбросов

Для проверки работы алгоритма поиска выбросов были проведены эксперименты, из которых был сделан вывод, что алгоритм удовлетворяет требованиям, поставленным к Препроцессору. При разработке к экспериментам были предложены два алгоритма:

- `SearchOutliersADTK()` – метод поиска аномалий ADTK из библиотеки Anomaly Detection Toolkit (adtk) [32];
- `SearchOutliersMedian()` – Поиск выбросов методом расчета разницы с медианой ряда.

Демонстрация работы этих алгоритмов представлена на рисунке 10 (а – ADTK, б – Median) в котором красными точками помечена точка, которую алгоритм посчитал выбросом.

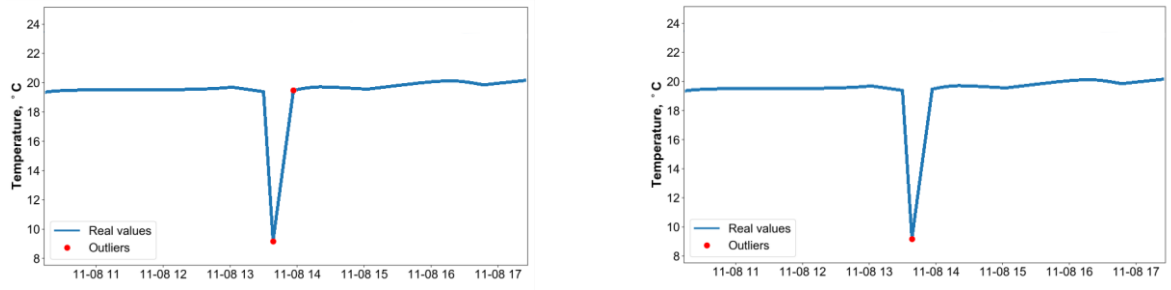

а) ADTK б) Median

Рисунок 10 – Замена выбросов временного ряда на правдоподобные синтетические значения

Представленные алгоритмы соответствуют требованиям, представленным в пункте 3.3. Для постоянной работы Препроцессора был выбран алгоритм ADTK. Так как на большем наборе данных при тестировании он показал большую точность работы.

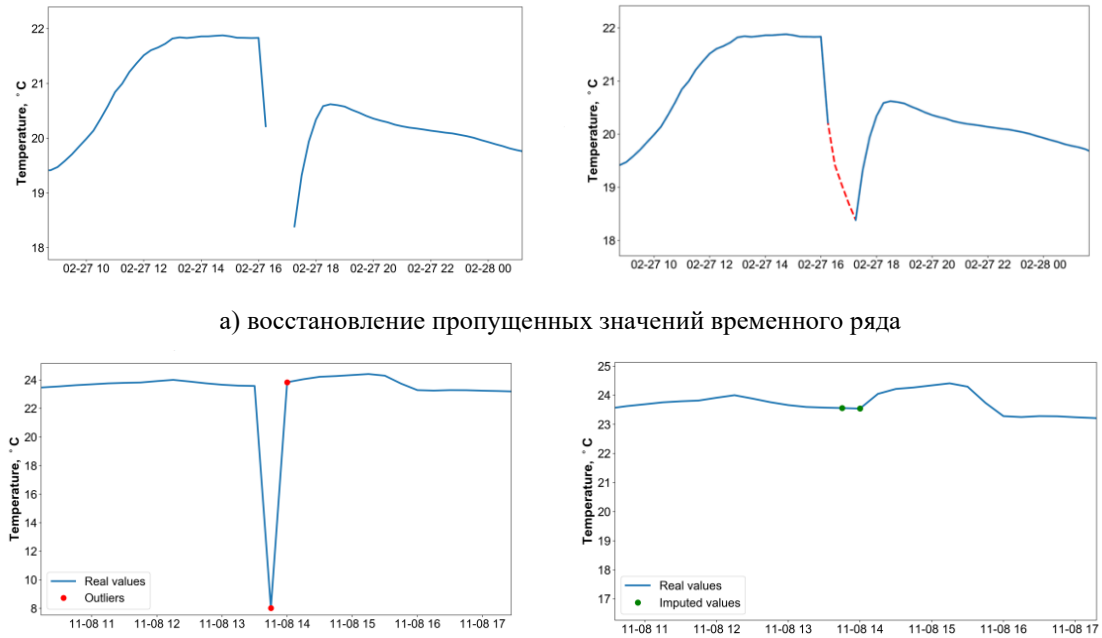

а) восстановление пропущенных значений временного ряда

б) Замена выбросов временного ряда на правдоподобные синтетические значения

Рисунок 11 – Результаты работы Восстановителя на основе модели `SARIMAX(6,1,5)(0,1,1)96` и алгоритмом восстановления ADTK

Результаты работы Препроцессора по восстановлению и удалению аномалий приведены на рисунке 11.

ЗАКЛЮЧЕНИЕ

В рамках данной работы был разработан Препроцессор, который выполняет функции обработки файлов формата *.xlsx, анализа временных рядов на наличие выбросов и пропусков, и применение алгоритмов к ним, для подготовки данных в дальнейшей работе модуля очистки данных. Реализованы алгоритмы поиска выбросов и очистки данных от них и восстановления пропущенных значений во временных рядах.

1. Произведен обзор литературы и существующих решений по предметной области.
2. Разработана архитектура Модуля очистки данных и препроцессора.
3. Выполнено проектирование системы.
4. Разработана и покрыта модальными и интеграционными тестами спроектированная система.
5. Проведены подбор паромоторов работы Препроцессора и проведены эксперименты.

В работе затронута проблема очистки данных, поступающих с температурных датчиков в интеллектуальных системах отопления умных домов. Рассмотрен случай SCADA-системы «ПолиТЭР», установленной в Южно-Уральском государственном университете для управления отоплением университетского кампуса. Представлены архитектура и принципы реализации модуля очистки данных, разработанного и внедренного в систему «ПолиТЭР».

В настоящий момент произведена интеграция, алгоритмов, представленных в работе в систему управления отоплением в ЮУрГУ. Проведены вычислительные эксперименты на реальных данных датчиков системы «ПолиТЭР», показавшие высокую точность работы Модуля очистки данных и Препроцессора.

В рамках работы были опубликованы следующие статьи:

1. Цымблер М.Л., Краева Я.А., Латыпова Е.А., Иванова Е.В., Шнайдер Д.А., Басалаев А.А. Очистка сенсорных данных в интеллектуальных системах управления отоплением зданий // Вестник ЮУрГУ. Серия: Вычислительная математика и информатика. 2021. Т. 10, № 3. С. 16–36. [DOI: 10.14529/cmse210302] [РИНЦ].

2. Zymbler M., Kraeva Ya., Latypova E., Kumar S., Shnayder D., Basalaev A. Cleaning Sensor Data in Smart Heating Control System // Proceedings of 2020 Global Smart Industry Conference, GloSIC 2020, Chelyabinsk, Russia, November 17–19, 2020. P. 375–381. [Scopus] [WOS:000646231600061] [DOI: 10.1109/GloSIC50886.2020.9267813].

Данная работа была представлена на международной конференции Cleaning Sensor Data in Smart Heating Control System. 2020 Global Smart Industry Conference, GloSIC 2020, (Chelyabinsk, Russia, November 17–19, 2020).

А также было получено свидетельство о государственной регистрации программы для ЭВМ представленный в Приложении Б (Цымблер М.Л., Краева Я.А., Латыпова Е.А. Свидетельство Роспатента о государственной регистрации программы для ЭВМ «Программная система очистки данных температурных датчиков для системы управления отоплением умного дома» № 2020662018 от 06.10.2020 [РИНЦ]).

Работа выполнена при финансовой поддержке Российского фонда фундаментальных исследований (грант № 20-07-00140) и Министерства образования и науки РФ (государственное задание FENU-2020-0022).

ЛИТЕРАТУРА

1. Zymbler M. и др. Cleaning Sensor Data in Smart Heating Control System // 2020 Global Smart Industry Conference (GloSIC). IEEE, 2020. С. 375–381.

2. Zymbler M. и др. Cleaning Sensor Data in Intelligent Heating Control System // Bull. South Ural State Univ. Ser. "Computational Math. Softw. Eng. 2021. Т. 10, № 3.

3. Basalaev A.A. Automated Energy Management for Heat and Power System of University Campus // Bull. South Ural State Univ. Ser. Comput. Technol. Autom. Control Radioelectron. 2015. Т. 15, № 4. С. 26–32.

4. Zhao Y. и др. Artificial intelligence-based fault detection and diagnosis methods for building energy systems: Advantages, challenges and the future // Renewable and Sustainable Energy Reviews. 2019. Т. 109. С. 85–101.

5. Zimmerman N., Dahlquist E., Kyprianidis K. Towards On-line Fault Detection and Diagnostics in District Heating Systems // Energy Procedia. 2017. Т. 105. С. 1960–1966.

6. Turner W.J.N., Staino A., Basu B. Residential HVAC fault detection using a system identification approach // Energy Build. 2017. Т. 151. С. 1–17.

7. Yan K., Ji Z., Shen W. Online fault detection methods for chillers combining extended kalman filter and recursive one-class SVM // Neurocomputing. 2017. Т. 228. С. 205–212.

8. Netbay G.V. и др. Managdment of a Local Urban Heat Supply System Based on Neural Network Modeling Taking into Account the Weather Forecast // Bull. South Ural State Univ. Ser. Comput. Technol. Autom. Control Radioelectron. 2020. Т. 20, № 3. С. 29–38.

9. Farouq S. и др. Large-scale monitoring of operationally diverse district heating substations: A reference-group based approach // Eng. Appl. Artif. Intell. 2020. Т. 90. С. 103492.

10. Hu Y. и др. A statistical training data cleaning strategy for the PCA-

based chiller sensor fault detection, diagnosis and data reconstruction method // Energy Build. 2016. Т. 112. С. 270–278.

11. Dunia R., Joe Qin S. Joint diagnosis of process and sensor faults using principal component analysis // Control Eng. Pract. 1998. Т. 6, № 4. С. 457–469.

12. Jha K. Minimal loop extraction for leak detection in water pipe network // 2012 1st International Conference on Recent Advances in Information Technology (RAIT). IEEE, 2012. С. 687–693.

13. Zhao Y. и др. A review of data mining technologies in building energy systems: Load prediction, pattern identification, fault detection and diagnosis // Energy Built Environ. 2020. Т. 1, № 2. С. 149–164.

14. Idowu S. и др. Applied machine learning: Forecasting heat load in district heating system // Energy Build. 2016. Т. 133. С. 478–488.

15. Ahmad T., Chen H., Huang Y. Short-Term Energy Prediction for District-Level Load Management Using Machine Learning Based Approaches // Energy Procedia. 2019. Т. 158. С. 3331–3338.

16. Basalaev A.A., Tochilkin M. V., Shnayder D.A. Enhancing Room Thermal Comfort Conditions Modeling in Buildings Through Schedule-Based Indicator Functions for Possible Variable Thermal Perturbation Inputs // 2019 International Conference on Industrial Engineering, Applications and Manufacturing (ICIEAM). IEEE, 2019. С. 1–8.

17. Batista G.E.A.P.A., Monard M.C. An analysis of four missing data treatment methods for supervised learning // Appl. Artif. Intell. 2003. Т. 17, № 5–6. С. 519–533.

18. Yozgatligil C. и др. Comparison of missing value imputation methods in time series: the case of Turkish meteorological data // Theor. Appl. Climatol. 2013. Т. 112, № 1–2. С. 143–167.

19. Box G.E.P. и др. TIME SERIES ANALYSIS: Forecasting and Control. 2015. 712 с.

20. Khayati M., B M.H. REBOM: Recovery of blocks of missing values in time series. 2012. С. 44–55.

21. Khayati M., Böhlen M., Gamper J. Memory-efficient centroid decomposition for long time series // Proceedings - International Conference on Data Engineering. IEEE Computer Society, 2014. С. 100–111.

22. Li L. и др. DynaMMo: Mining and summarization of coevolving sequences with missing values // Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. 2009. С. 507–515.

23. Yi B.-K. и др. Online data mining for co-evolving time sequences // Proceedings of 16th International Conference on Data Engineering (Cat. No.00CB37073). IEEE Comput. Soc, 2000. С. 13–22.

24. Papadimitriou S. и др. Dimensionality Reduction and Filtering on Time Series Sensor Streams // Managing and Mining Sensor Data. Boston, MA: Springer US, 2013. С. 103–141.

25. Papadimitriou S., Sun J., Faloutsos C. Streaming pattern discovery in multiple time-series // VLDB 2005 - Proc. 31st Int. Conf. Very Large Data Bases. 2005. Т. 2. С. 697–708.

26. Wilson G.T. Time Series Analysis: Forecasting and Control, 5th Edition, by George E. P. Box, Gwilym M. Jenkins, Gregory C. Reinsel and Greta M. Ljung, 2015. Published by John Wiley and Sons Inc., Hoboken, New Jersey, pp. 712. ISBN: 978-1-118-67502-1 // J. Time Ser. Anal. 2016. Т. 37, № 5. С. 709–711.

27. Dickey D.A., Fuller W.A. Distribution of the Estimators for Autoregressive Time Series With a Unit Root // J. Am. Stat. Assoc. 1979. Т. 74, № 366. С. 427.

28. Kwiatkowski D. и др. Testing the null hypothesis of stationarity against the alternative of a unit root // J. Econom. 1992. Т. 54, № 1–3. С. 159–178.

29. Python [Электронный ресурс]. URL: https://www.python.org (дата обращения 22.05.2022 г.).

30. A Python library to read/write Excel 2010 xlsx/xlsm files [Электронный ресурс]. URL: https://openpyxl.readthedocs.io/en/stable/ (дата обращения 22.05.2022 г.).

31. pandas [Электронный ресурс]. URL: https://pandas.pydata.org/ (дата обращения 22.05.2022 г.).

32. Anomaly Detection Toolkit, User Guide [Электронный ресурс]. URL: https://arundo-adtk.readthedocshosted.com/en/stable/userguide (дата обращения 22.05.2022 г.).

33. Statsmodels [Электронный ресурс]. URL: https://www.statsmodels.org/stable/index.html (дата обращения 22.05.2022 г.).

34. Scikit-learn [Электронный ресурс]. URL: https://scikit-learn.org/ (дата обращения 22.05.2022 г.).

35. NumPy [Электронный ресурс]. URL: https://numpy.org/ (дата обращения 22.05.2022 г.).

36. matplotlib [Электронный ресурс]. URL: https://matplotlib.org/ (дата обращения 22.05.2022 г.).

37. unittest [Электронный ресурс]. URL: https://docs.python.org/3/library/unittest.html (дата обращения 22.05.2022 г.).

ПРИЛОЖЕНИЯ

ПРИЛОЖЕНИЕ А. Спецификация вариантов использования

Спецификация основных вариантов использования приведены в таблицах 1–4.

Таблица 1 – Спецификация варианта использования «Отправить сырые данные»

Прецедент: Отправить сырые данные.
ID: 1.
Аннотация: Отправка данных для преобразования в препроцессор
Главные актеры: External system (Внешняя система)
Второстепенные актеры: Нет
Предусловия: Нет
Основной поток: 1. Поток инициируется, когда система посылает данные в препроцессор; 2. Препроцессор запускает преобразование данных;
Постусловия: Нет.
Альтернативные потоки: Если формат файла не поддерживается или данные не консистентные система возвращает сообщение об ошибке.

Таблица 2 – Спецификация варианта использования «Получить обучающую выборку»

Прецедент: Получить обучающую выборку.
ID: 2.
Аннотация: Внешней системе возвращаются данные после восстановления нормализации и удаления выбросов.
Главные актеры: External system (Внешняя система)
Второстепенные актеры: Нет
Предусловия: Данные должны пройти преобразование.
Основной поток: 1. Поток инициируется, когда препроцессор завершит преобразование данных; 2. Внешняя система получает данные в виде csv-файла.
Постусловия: Нет.
Альтернативные потоки: Нет

Таблица 3 – Спецификация варианта использования «Получить восстановленные данные»

Прецедент: Получить восстановленные данные.
ID: 3.
Аннотация: Внешняя система сохраняет в csv-файл промежуточные данные.
Главные актеры: External system (Внешняя система)
Второстепенные актеры: Нет
Предусловия: Данные должны пройти этап восстановления и очистки выбросов без нормализации.
Основной поток: 1. Поток инициируется, когда завершился этап удаления выбросов и восстановления; 2. Внешняя система получает csv-файл с данными.
Постусловия: Нет.
Альтернативные потоки: Данные не записались в файл;

Таблица 4 – Спецификация варианта использования «Преобразовать данные»

Прецедент: Преобразовать данные.
ID: 4.
Аннотация: Данные поступили на алгоритмы препроцессора.
Главные актеры: Нет
Второстепенные актеры: Нет
Предусловия: Данные должны быть консистентными после извлечения из файла.
Основной поток: Поток инициируется, когда с парсера приходят данные на алгоритм восстановления.
Постусловия: Нет.
Альтернативные потоки: Нет

ПРИЛОЖЕНИЕ Б. Свидетельство о государственной регистрации программы для ЭВМ

РОССИЙСКАЯ ФЕДЕРАЦИЯ

СВИДЕТЕЛЬСТВО

о государственной регистрации программы для ЭВМ

№ 2020662018

Программная система очистки данных температурных датчиков для системы управления отоплением умного дома

Правообладатель: *федеральное государственное автономное образовательное учреждение высшего образования «Южно-Уральский государственный университет (национальный исследовательский университет)» (ФГАОУ ВО «ЮУрГУ (НИУ)» (RU)*

Авторы: *Цымблер Михаил Леонидович (RU), Краева Яна Александровна (RU), Латыпова Елизавета Альбертовна (RU)*

Заявка № 2020660986

Дата поступления 28 сентября 2020 г.

Дата государственной регистрации

в Реестре программ для ЭВМ *06 октября 2020 г.*

Руководитель Федеральной службы по интеллектуальной собственности

Г.П. Ивлиев